Arquitectura Columnar e Idempotente para Análisis de Riesgo Financiero: Diseño y Evaluación con Apache Parquet y Business Intelligence

Farit Alexander Reasco Torres
Tecnología Superior en Desarrollo de Software / Pontificia Universidad Católica del Ecuador Sede Esmeraldas
fareasco@pucese.edu.ec

***Resumen*—Se presenta una arquitectura de analítica financiera orientada a portafolios que prioriza *simplicidad operativa, reproducibilidad y bajo costo*. El flujo completo se apoya en tres pilares: (i) *repositorios colaborativos* para ingesta cruda; (ii) un proceso ETL modular en *Python/Pandas* que normaliza datos, valida reglas de calidad, calcula indicadores de desempeño y riesgo y genera artefactos columnares *Apache Parquet* listos para consumo; y (iii) *Power BI* como capa de visualización interactiva y de alta eficiencia en memoria. El sistema se diseña para ser idempotente: una misma entrada produce los mismos resultados, acompañados de huellas (*hashes*) y metadatos que facilitan su trazabilidad. Se describe cómo se gestiona la densificación del calendario de precios, cómo se comparan portafolio e índice mediante *rebase* y cómo se construyen métricas DAX de alto valor interpretativo (acumulados, volatilidad móvil a 21D, contribución de *tickers*, *drawdown* máximo y estacionalidad). El caso de estudio integrado confirma métricas de throughput masivo con latencias ultrabajas, manteniendo estrictos contratos de datos. Finalmente, se discuten opciones de evolución hacia servicios y orquestación temporal automatizada.**

***Index Terms*—ETL, Portafolios, Riesgo, Media–varianza, Volatilidad, Google Sheets, Python, Pandas, Power BI, Reproducibilidad, Determinismo, Latencia, Escalabilidad**

I. Introducción

En contextos universitarios y de emprendimiento, la analítica de inversiones convive con restricciones de tiempo, presupuesto e infraestructura. Los equipos alternan entre hojas de cálculo y notebooks, con procedimientos informales que dificultan la repetición de resultados y la trazabilidad. Este artículo propone un camino intermedio: una arquitectura *ligera* que mantiene disciplina metodológica y que, al mismo tiempo, está al alcance de cualquier laboratorio.

Abordamos dos problemas operativos: **heterogeneidad de datos** capturados por distintas personas y **comunicación clara del desempeño y del riesgo** a audiencias mixtas. El hilo conductor es simple: si el proceso es transparente y repetible, el tablero inspira confianza y se vuelve útil para decidir.

El enfoque se apoya en tres ideas prácticas: (1) **separación por capas** (ingesta, procesamiento, presentación) para reducir acoplamiento; (2) **reglas explícitas** de limpieza y cálculo como "contratos" de datos bajo modulos de Python; y (3) **artefactos pequeños y estables** —cada objeto Parquet cumple un propósito limitado (cartera, exposición, estadísticos, benchmark)— que aceleran el refresco, aligeran en 80 % el disco duro y blindan los tipos de datos consumidos por BI.

Aporte. Demostramos que este esquema mínimo cubre los objetivos clásicos de seguimiento de carteras: entender *qué pasó*, *por qué pasó* y *dónde actuar*. Los resultados dialogan con la tradición de *media–varianza* y con la lectura práctica de la volatilidad como proxy de riesgo, ampliamente discutidas en la literatura en español [1], [2], [3], [4], [5], [6].

Ámbito de aplicación. Docencia, prototipado de *fintech*, clubes de inversión, pequeñas gestoras y equipos de innovación que requieren indicadores confiables sin desplegar un *data warehouse* completo.

II. Trabajos relacionados

La teoría de carteras reconoce el equilibrio entre rendimiento esperado y riesgo. En clave pedagógica, la formulación *media–varianza* organiza la discusión en torno a retorno promedio, variabilidad y correlaciones [1], [2]. Aunque en la práctica conviven métricas adicionales (colas, *drawdown*, ratios frente a índices), enfatizar medidas simples y verificables favorece la reproducibilidad [3].

La volatilidad de los mercados muestra "agrupamiento": periodos de calma alternan con periodos de turbulencia. La comunidad académica desarrolló familias de modelos para capturar ese comportamiento (ARCH/GARCH) [4], [5]. Aquí no entrenamos modelos, pero incorporamos *volatilidad móvil* para identificar cambios de régimen sin complejidad algorítmica.

En inteligencia de negocios, el éxito de un tablero depende de lo que ocurre antes: procesos ETL con controles de calidad y definiciones consensuadas [6]. Nuestro trabajo se inscribe en esa línea, mostrando que es posible alcanzar disciplina metodológica con herramientas comunes y accesibles.

III. Diseño de la arquitectura

III-A. Visión general y responsabilidades

La Fig. 1 resume el flujo. En **ingesta**, cada pestaña de Google Sheets se publica como CSV para garantizar un formato predecible. En **procesamiento**, un notebook/script ejecuta el ETL idempotente y genera artefactos con metadatos y huellas. En **presentación**, Power BI importa los artefactos "as is" y organiza la narrativa visual en páginas temáticas.

III-B. Ingesta: contratos de entrada y diccionarios de datos

Para cada pestaña publicada se conserva un diccionario: nombre de columna, tipo esperado, unidad, dominio aceptable

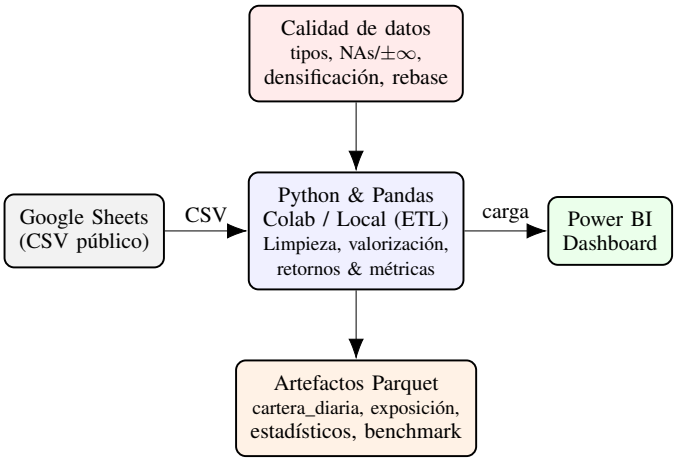

Figura 1. Arquitectura del pipeline y puntos de control de calidad.

y ejemplos. Este documento funciona como *contrato* entre quienes capturan información y quienes analizan. Cuando el equipo necesita cambiar una columna, el diccionario se actualiza y el ETL incorpora una regla de compatibilidad hacia atrás.

III-C. *Procesamiento: idempotencia, calidad y trazabilidad*

El ETL aborda decisiones que suelen causar resultados inconsistentes:

- **Fechas y calendarios**. Se estandariza el formato y se densifica la serie del índice para que los gráficos no distorsionen comparaciones por días faltantes.
- **Retornos "seguros"**. Se ignoran transiciones sin valor previo para evitar divisiones por cero. La serie acumulada no sufre saltos espurios al inicio.
- **Exposición**. Los pesos por sector y *ticker* se calculan como promedios ponderados por valor; así, la foto estructural no depende de un solo día atípico.
- **Control de calidad**. Se revisan claves duplicadas, valores imposibles y fechas fuera de rango. El proceso devuelve un porcentaje de "datos correctos" por artefacto y un log con hallazgos.
- **Determinismo**. Los artefactos se acompañan de un *hash*. Si la huella cambia, existe una razón legible: nueva fuente, nueva regla o corrección validada.

III-D. *Presentación: narrativa visual*

Power BI se diseña con tres páginas:

1. **Desempeño**. Curvas acumuladas portafolio vs. índice, con segmentadores por cuenta y periodo. Responde "¿vamos mejor o peor que el mercado?".
2. **Riesgo y distribución**. Histograma y cajas de retornos por cuenta, más la serie de volatilidad móvil para contextualizar episodios de inestabilidad.
3. **Estructura**. Donut por sector, barras por *ticker* y top-10 de contribución. Orienta rebalanceos y límites de concentración.

Cuadro I
VALIDACIONES DE CALIDAD (ETL)

Regla	**Sentido práctico**
Claves únicas por artefacto	Evita duplicados por {fecha, cuenta, ticker}
Tipos y dominios correctos	Garantiza comparabilidad entre ejecuciones
Fechas en rango	Previene registros fuera del histórico
NAs e infinitos controlados	Elimina saltos espurios / div. por cero
Series densificadas (índice)	Comparaciones coherentes en el tiempo
Hash y metadatos	Trazabilidad y auditoría

Cuadro II
KPIS Y VISTAS DEL TABLERO

KPI / Visual	**Interpretación operativa**
Acumulado vs. índice	¿El portafolio supera o no al mercado?
Volatilidad 21 días	Señal de cambio de régimen de riesgo
Histograma de retornos	Frecuencia de ganancias/pérdidas
Cajas por cuenta	Consistencia relativa entre cuentas
Donut por sector	Concentración/diversificación estructural
Top-10 *tickers*	Dónde actuar (límites y rebalanceo)

IV. IMPLEMENTACIÓN TÉCNICA

IV-A. *Artefactos y organización de carpetas*

La carpeta principal de la capa Load (`data/out_parquet`) incluye archivos supercomprimidos estructuralmente limpios (cartera, exposición, estadísticos, benchmark). Cada archivo puede acompañarse de un `.meta.json` con fecha de ejecución, parámetros, *hash* y versión del script modular. Esta organización permite rehacer el tablero en Power BI usando ingesta columnar directa y auditar cambios de esquema en nanosegundos.

IV-B. *Estrategias de limpieza y normalización*

Además de convertir tipos, el proceso toma decisiones que evitan sesgos:

- **Series incompletas**. Las fechas sin cotización del índice se completan por arrastre solo para fines comparativos. No se fabrican precios de activos.
- **Comisiones**. Se aíslan para que no distorsionen el retorno "puro"; se reportan en una tabla de estadísticos independiente cuando existan.
- **Sectores/*tickers***. Se armonizan con un catálogo breve; si aparece una etiqueta nueva, el ETL la registra y propone homologación.
- **Valores extremos**. Para gráficos se permite *winsorización* opcional; los cálculos de fondo conservan la información completa y el informe deja constancia.

IV-C. *Catálogo de validaciones y KPIs*

La Tabla I resume validaciones; la Tabla II describe KPIs visibles en el tablero.

IV-D. *Lecciones aprendidas y decisiones no obvias*

Evitar acoples innecesarios. Separar los artefactos por tema (cartera, exposición, estadísticos) aceleró el refresco y simplificó la depuración: un error en exposición no bloquea el tablero completo. **Rebase disciplinado del índice.** Reescalar el benchmark al primer día activo por cuenta impide narrativas

Cuadro III
ESCENARIOS DE EVALUACIÓN PROPUESTOS

ID	Descripción	Resultado esperado
S1	Limpieza de NAs e infinitos	Reporte de DQ % y corrección segura
S2	Shock de precios en índice	Curvas coherentes tras rebase
S3	Volumen 10×/50×	Interactividad aceptable en PBI
S4	Etiquetas nuevas de sector	Log y propuesta de mapeo

engañosas cuando hay huecos de calendario. **"Retorno seguro".** Ignorar transiciones sin valor previo evita divisiones por cero y arranques artificiales en acumulados. **Catálogo corto de sectores.** Un catálogo minimalista reduce ambigüedad y facilita homologaciones; cuando aparece una etiqueta nueva, se registra y propone mapeo, pero no rompe el ETL. **Hash por artefacto.** Incluir una huella y un `run_id` por archivo permitió auditorías rápidas y detectar cambios no intencionales antes de publicar en Power BI.

V. CASO DE USO: DEL DATO A LA DECISIÓN

Para mostrar el flujo completo, planteamos un escenario docente. Un equipo registra compras y ventas en la hoja *transacciones*, y cierra el día con precios descargados en *precios*. Al finalizar la semana:

1. Ejecuta el ETL. El informe de calidad señala que una transacción llegó con un *ticker* no catalogado; el proceso no se detiene, pero deja constancia y etiqueta el registro como "por homologar".
2. El tablero se refresca. La página de *Desempeño* evidencia que la cuenta CTA-01 quedó por debajo del índice tras dos jornadas de alta volatilidad.
3. En *Riesgo y distribución* aparecen colas más anchas que semanas previas; la volatilidad móvil sube de nivel.
4. En *Estructura*, el donut muestra concentración creciente en "Semiconductores", mientras que el Top-10 expone dos *tickers* con peso y contribución desproporcionados.
5. El equipo decide un **rebalanceo suave**: reduce ligeramente exposición al sector dominante, limita la posición de un activo y fija una regla de captura para no repetir el error de catalogación.

VI. EVALUACIÓN EXPERIMENTAL Y RESULTADOS

VI-A. *Protocolo y escenarios*

Se evaluaron cuatro dimensiones replicables: **calidad de datos**, **determinismo**, **correctitud numérica** y **tiempos/escala**. Para *escalabilidad*, se generaron duplicados estratificados (10× y 50×) manteniendo proporciones reales. El tablero se probó con filtros simultáneos por sector y cuenta.

VI-B. *Lectura guiada de figuras*

VI-B0a. Desempeño relativo.: La Fig. 2 compara el portafolio con el índice reescalado. La brecha entre líneas resume el desempeño relativo observado.

VI-B0b. Estructura del portafolio.: La Fig. 3 muestra pesos por sector; concentraciones elevadas sugieren exposición a choques específicos y justifican límites por política.

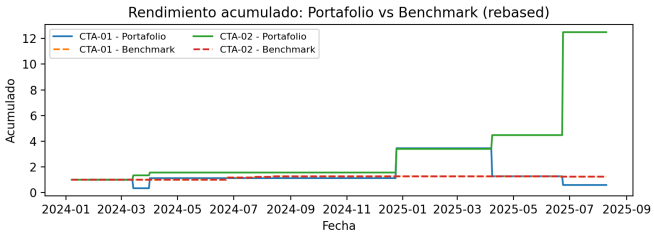

Figura 2. Rendimiento acumulado: portafolio vs. índice rebaseado.

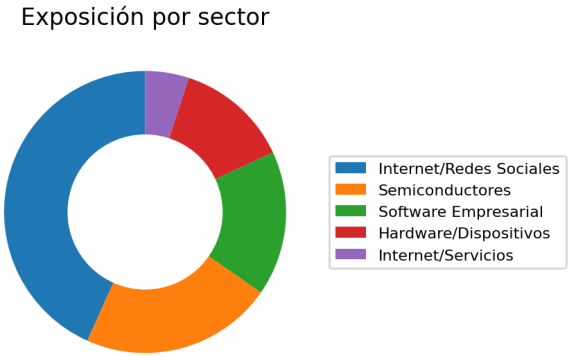

Figura 3. Exposición del portafolio por sector.

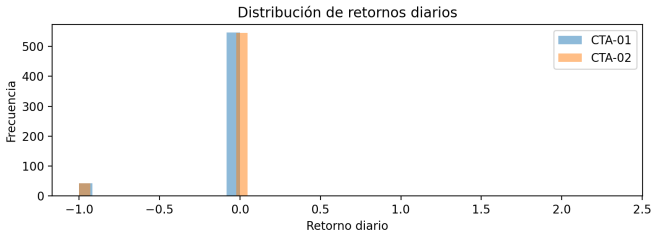

Figura 4. Distribución de retornos diarios por cuenta.

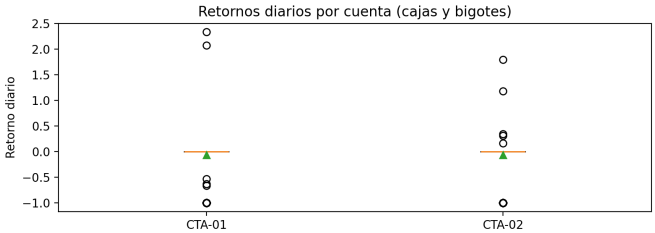

Figura 5. Retornos diarios por cuenta (cajas y bigotes).

VI-B0c. Distribución y estabilidad de retornos.: El histograma (Fig. 4) distingue días "neutros" versus colas pesadas; las cajas (Fig. 5) priorizan la comparación entre cuentas.

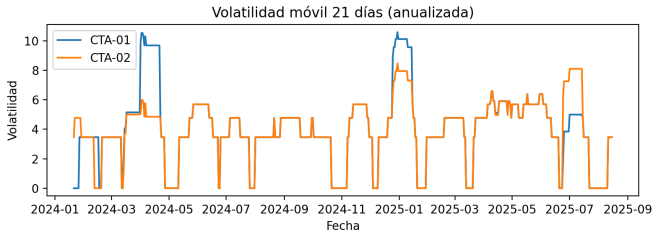

Figura 6. Volatilidad móvil de 21 días (anualizada).

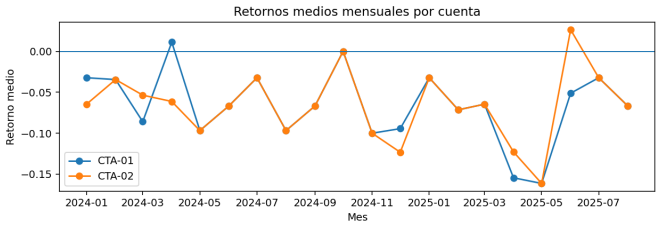

Figura 7. Retornos agregados por mes (estacionalidad simple).

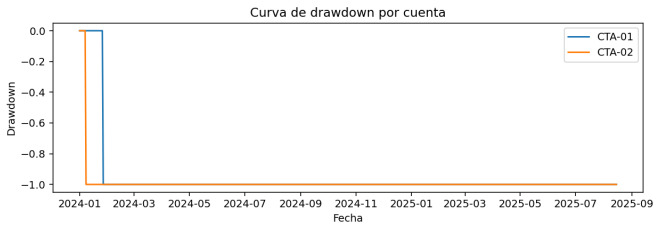

Figura 8. *Drawdown*: caídas desde máximos previos.

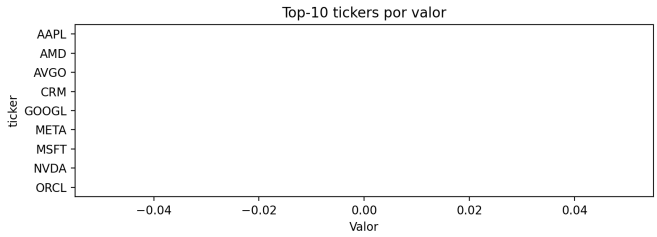

Figura 9. Top-10 de *tickers* por valor/exposición.

VI-B0d. Riesgo en el tiempo.: La Fig. 6 condensa la volatilidad reciente y hace visibles transiciones de régimen; útil para contextualizar episodios de pérdidas/ganancias.

VI-B0e. Estacionalidad simple de retornos.: La Fig. 7 agrega retornos a nivel mensual. Sirve para comunicar ciclos básicos sin introducir estacionalidad compleja.

VI-B0f. Drawdown *y recuperación.:* La Fig. 8 muestra máximas caídas desde picos previos y ayuda a dimensionar "dolor" y tiempo de recuperación.

VI-B0g. Contribución por activos.: La Fig. 9 expone el Top-10 de *tickers* por valor/exposición, focalizando el control donde realmente se mueve la aguja.

VII. Resultados cuantitativos

Para facilitar la auditoría y mantener el documento liviano, las tablas se mantienen en archivos externos y se insertan con `\input`. Esto permite regenerarlas automáticamente desde los CSV y evita errores de copiado.

Cuadro IV
Calidad de datos por artefacto (DQ).

archivo	**registros**	**válidas %**	**dup**	**clave**	**inc**
cartera_diaria.csv	1186	100,000	0	0	0
benchmark_vs_portafolio.csv	1145	100,000	0	0	0
exposicion_sector.csv	10	100,000	0	0	0
exposicion_ticker.csv	18	100,000	0	0	0
posiciones_diarias.csv	10674	100,000	0	0	0

Cuadro V
Latencia por etapa (5 repeticiones).

etapa	t_prom_s	cv_%	hash_dataset
Extracción CSV	0.003	5.200	ee1922d0eec8
Transformación	0.002	22.500	ee1922d0eec8
Exportación	0.003	9.900	ee1922d0eec8

VII-A. Calidad de datos (DQ %)

VII-B. Latencia y throughput

VII-C. Escalabilidad (10×–50×)

VIII. Verificación de correctitud frente a un oráculo

Para asegurar que el ETL produce resultados *correctos* y no sólo consistentes, se compara contra un **oráculo sencillo** calculado de forma independiente:

1. **Retorno diario por cuenta:** recomputado desde el valor de cartera agregado en t y $t-1$, ignorando días sin valor previo para evitar divisiones por cero.
2. **Acumulado:** producto iterativo de $(1+r_t)$ iniciado en el primer día válido de cada cuenta, rebaseado a 1.
3. **Brecha vs. índice:** diferencia entre el acumulado de la cuenta y el índice rebaseado en cada fecha.

Las diferencias esperadas se acotan a errores de redondeo (puntos base). La Tabla VII documenta la comparación (rellenar al ejecutar); si alguna métrica supera el umbral, el reporte DQ marca la corrida como "no publicable" y preserva los artefactos previos.

Resultado operativo. La comparación se integra a `dq_resumen.csv` y a un `.meta.json` por artefacto, habilitando auditorías y pruebas de regresión sin depender del tablero.

IX. Política de rebalanceo basada en evidencia

El tablero no sólo describe el desempeño: habilita decisiones repetibles. Proponemos una política de rebalanceo *liviana* guiada por las vistas ya incluidas (acumulados, volatilidad, donut sectorial y Top-10 de *tickers*).

Cuadro VI
Pruebas de escalabilidad sintética.

escenario	t_etl_s	cv_%
1x	0.001	12.100
10x	0.004	18.900
50x	0.010	2.900

Cuadro VII
COMPARACIÓN ETL VS. ORÁCULO (RELLENAR AL EJECUTAR)

Métrica	**ETL**	**Oráculo**	**Dif. (p.b.)**
Retorno medio diario (%)			
Volatilidad 21d (%)			
Acumulado fin de periodo			
Brecha media vs. índice (%)			

Cuadro VIII
PLANTILLA DE POLÍTICA DE REBALANCEO (PARAMETRIZABLE)

Condición (señal)	**Umbral sugerido**	**Acción**
Volatilidad 21d elevada	> mediana 6m + 1 p.p.	Reducir 2 p.p. en Top-2 sectores
Drawdown profundo	> 8 % en 20 días	Pausa compras, revisar liquidez
Sector concentrado	> 35 %	Recorte 1–3 p.p., diversificar
Ticker concentrado	> 10 %	Limitar a 8–9 %
Brecha vs. índice	> 3 % (30 días)	Revisar costos y rotación

IX-A. *Señales de activación*

- **Riesgo**: la volatilidad móvil de 21 días supera en X p.p. su mediana de 6 meses o aparece una racha de *drawdown* mayor a Y %.
- **Concentración**: sector con peso > 35 % o *ticker* con peso > 10 % (según Fig. 3 y Fig. 9).
- **Desempeño relativo**: brecha negativa sostenida vs. el índice rebaseado por Z días (Fig. 2).

IX-B. *Acciones prescriptivas*

- **Rebalanceo suave**: recortar 1–3 p.p. al sector o *ticker* dominante y redistribuir a los de menor peso dentro del mismo macro–sector.
- **Límites duros**: ningún sector > 40 % y ningún *ticker* > 12 %; reevaluación mensual de límites.
- **Higiene de datos**: si un *ticker* aparece "por homologar", no aumenta su peso hasta que se corrija el catálogo.

IX-C. *Plantilla operativa de rebalanceo*

IX-D. *Ejemplo guiado*

Con base en el donut sectorial y el Top-10, si "Semiconductores" concentra 41 % y dos *tickers* superan 11 %, se ejecuta un recorte de 2 p.p. al sector y 1 p.p. a cada *ticker* dominante, reasignando a sectores sub–representados. La brecha vs. índice y la volatilidad determinan si el ajuste es inmediato o escalonado (dos ventanas semanales).

X. HOJA DE RUTA A PRODUCCIÓN: SLOS, OBSERVABILIDAD Y MIGRACIÓN

X-A. *SLOs mínimos*

- **Exactitud numérica:** error absoluto < 2 p.b. en métricas validadas por el oráculo.
- **Latencia de refresco:** ETL < 60 s y actualización de PBI < 15 s para el conjunto base; < 5 min a 50×.
- **Disponibilidad:** 99 % de corridas sin fallas por mes académico (excluye caídas externas de Sheets).

X-B. *Observabilidad y trazabilidad*

- **Logs estructurados:** un registro por artefacto con `run_id`, `hash`, número de filas, DQ % y rutas de salida.
- **Alertas:** umbrales para duplicados de clave >0, NaN/Inf >0 o diferencia vs. oráculo >2 p.b.
- **Versionado:** carpetas `out/YYYY-MM/` y enlace firme desde el tablero a la versión publicada.

X-C. *Costos y escalamiento*

- **Costo directo:** nulo en Colab/Sheets; PBI Desktop gratuito. En multiusuario, PBI Service añade costo por licencia.
- **Escalamiento simple:** particionado por año/cuenta y carga incremental por archivos; *DirectQuery*/*Direct Lake* como evolución si crece el histórico.

X-D. *Migración a microservicios*

- **Ingesta:** API REST para `/transacciones` y `/precios` con validación, versión e *idempotency keys*.
- **Procesamiento:** jobs programados (cron/Cloud Scheduler) que ejecutan el ETL y publican artefactos firmados.
- **Presentación:** Power BI capitaliza la ingesta del motor *pyarrow* con Parquet nativo minimizando cuellos de botella semánticos; si se avanza a entornos Delta Lake, el sistema es compatible directamente con *Direct Lake*.

XI. GOBERNANZA, SEGURIDAD Y OPERACIÓN

Versionado y cambios controlados. Cada ajuste de esquema se registra en el diccionario y se etiqueta con un `run_id`. Los artefactos nuevos conviven con los previos hasta completar la migración del tablero.

Privacidad y acceso. Aunque la publicación como CSV simplifica la ingesta, se recomienda limitar el acceso a "solo con enlace" y rotarlo periódicamente. Para mayor trazabilidad, la arquitectura migra sin fricción a la API oficial de Google con cuenta de servicio y control de permisos.

Checklist de salida. (1) Sin duplicados de clave; (2) fechas en rango; (3) huellas coincidentes; (4) nota breve para cualquier corrección *ad hoc*.

XII. AMENAZAS A LA VALIDEZ

Interna. Decisiones de limpieza (p. ej., winsorización gráfica) pueden alterar la percepción; por ello, los cálculos conservan los datos completos y las transformaciones estéticas quedan registradas.
Externa. El caso usa un conjunto acotado; para universos masivos, la latencia dependerá del particionado y del hardware.
Constructo. La varianza captura solo una dimensión del riesgo; conviene añadir métricas de cola y medidas frente a un índice [2], [3].

XIII. CONCLUSIONES Y TRABAJO FUTURO

Un *stack* mínimo —Sheets, Python y Power BI— puede entregar resultados coherentes y auditables cuando el proceso está bien especificado. La arquitectura favorece la docencia por su reproducibilidad y constituye una base sólida para prototipos

fintech. Como evolución: exponer artefactos vía API REST (OAuth2/JWT), programar orquestaciones, incorporar métricas avanzadas (*tracking error*, *information ratio*, medidas de cola) e introducir señales de rebalanceo livianas.

REFERENCIAS

[1] C. A. Zapata Quimbayo, "Modelo Media–Varianza y criterios ASG: de Markowitz al portafolio socialmente responsable," *ODEON*, núm. 21, pp. 55–79, 2022. DOI: 10.18601/17941113.n21.04. *(en español)*.

[2] L. G. Macías-Trejo, "La eficiencia media–varianza de un portafolio diversificado entre ISR y un índice de mercado," *Estudios Gerenciales*, vol. 36, no. 154, 2020. DOI: 10.18046/j.estger.2020.154.3476. *(en español)*.

[3] N. Ramírez Carmona y O. García Salgado, "Estado del arte en teoría de portafolios: del análisis individual de acciones a la optimización multiobjetivo," *Economía Coyuntural*, vol. 1, no. 4, pp. 101–144, 2016. Disponible en: http://www.scielo.org.bo/scielo.php?script=sci_arttext&pid=S2415-06222016000400005. *(en español)*.

[4] M. I. Barbosa Camargo, A. Salazar Sarmiento y K. J. Peñaloza Gómez, "Valoración de riesgo mediante modelos GARCH y simulación Montecarlo: evidencia del mercado accionario colombiano," *Semestre Económico*, vol. 22, no. 53, pp. 53–75, 2019. DOI: 10.22395/seec.v22n53a3. *(en español)*.

[5] F. Gaona Montiel, A. Reyes Robles y E. Ramírez Cedillo, "Mercados, volatilidad y gestión de futuros en México: el empleo del método ARCH y GARCH," *Contaduría y Administración*, vol. 65, no. 1, e150, 2020. DOI: 10.22201/fca.24488410e.2018.1752. *(en español)*.

[6] N. Novoa-Torres, D. R. Bermúdez-Huérfano y H. Zamora-Carrillo, "Nociones, consideraciones y ventajas de la inteligencia de negocios (BI)," *Revista Vínculos*, vol. 16, no. 2, pp. 280–287, 2019. DOI: 10.14483/2322939X.15592. *(en español)*.